1. Ejercicio 1 — Exploración y caracterización del dispositivo

1.1. Parte A — Inspección estática con nvidia-smi

1.1.1. Apuntes:

1.1.1.1. Modelo exacto de GPU.
NVIDIA GeForce RTX 5070 Ti

1.1.1.2. Memoria total y memoria actualmente en uso.
4819MiB / 16303MiB

1.1.1.3. Versión del driver NVIDIA.
Driver Version: 591.74

1.1.1.4. Estado de utilización (GPU utilization) y consumo/potencia.
5%, 22W / 300W

1.1.1.5. Si aparece, información relacionada con PCIe (p. ej. generación/anchura) o con clocks
Bus ID: 00000000:01:00.0

1.1.2. Cuestiones:

1.1.2.1. ¿La memoria que muestra nvidia-smi es la RAM del sistema o memoria dedicada de la GPU? (recuerda la orden free para observar la cantidad de memoria RAM en tu sistema).
Es la VRAM que tiene la gráfica, no es la RAM del sistema.

1.1.2.2. ¿Qué significa exactamente GPU utilization? ¿Puede ser baja aunque haya memoria ocupada?
GPU utlization es el ratio de tiempo en los que los SMs estuvieron activos. Sí puede ser baja aunque la memoria esté muy ocupada porque mide el cómputo y no la utilización de memoria.

1.1.2.3. ¿Qué te sugiere el hecho de que se muestre potencia/consumo? ¿Por qué es relevante en sistemas equipados con GPU?
Es una consecuencia y métrica real de la carga computacional por la que esté pasando la GPU, por lo que es importante. Si la potencia/consumo de la GPU es alta es que está con mucho cómputo y se queda limitada por la temperatura antes de que se queme.

1.1.3. Parte A.2 — Inspección detallada con nvidia-smi -q

1.1.3.1. Apuntes:

1.1.3.1.1. capacidad de memoria y tipo (si aparece),

```
FB Memory Usage
    Total                    : 16303 MiB
    Reserved                 : 308 MiB
    Used                     : 4704 MiB
    Free                     : 11292 MiB
```

1.1.3.1.2. clocks (gráficos/memoria),

```
Clocks
    Graphics                 : 487 MHz
    SM                       : 487 MHz
    Memory                   : 405 MHz
    Video                    : 600 MHz
```

1.1.3.1.3. información del enlace PCIe (si aparece)

GPU Link Info

```
PCIe Generation
    Max                    : 5
    Current                : 5
    Device Current         : 5
    Device Max             : 5
    Host Max               : 5
Link Width
    Max                    : 16x
    Current                : 16x
```

1.2. Parte B — Observación dinámica: ejecución de un kernel básico antes:

```
cynthia@HIRUELA-TV: ~/gpu

Every 0.1s: nvidia-smi                          HIRUELA-TV: Sat Feb 14 00:46:18 2026

Sat Feb 14 00:46:18 2026
+-----------------------------------------------------------------------------------------+
| NVIDIA-SMI 590.52.01              Driver Version: 591.74         CUDA Version: 13.1     |
+-----------------------------------------+------------------------+----------------------+
| GPU  Name                 Persistence-M | Bus-Id          Disp.A | Volatile Uncorr. ECC |
| Fan  Temp   Perf          Pwr:Usage/Cap |           Memory-Usage | GPU-Util  Compute M. |
|                                         |                        |               MIG M. |
|=========================================+========================+======================|
|   0  NVIDIA GeForce RTX 5070 Ti     On  |   00000000:01:00.0  On |                  N/A |
| 34%   47C    P0             43W /  300W |    4511MiB /  16303MiB |      1%      Default |
|                                         |                        |                  N/A |
+-----------------------------------------+------------------------+----------------------+

+-----------------------------------------------------------------------------------------+
| Processes:                                                                              |
|  GPU   GI   CI              PID   Type   Process name                        GPU Memory |
|        ID   ID                                                               Usage      |
|=========================================================================================|
|    0   N/A  N/A              39      G   /Xwayland                              N/A      |
+-----------------------------------------------------------------------------------------+
```

mientras:

```
cynthia@HIRUELA-TV: ~/gpu

Every 0.1s: nvidia-smi                          HIRUELA-TV: Sat Feb 14 00:46:47 2026

Sat Feb 14 00:46:47 2026
+-----------------------------------------------------------------------------------------+
| NVIDIA-SMI 590.52.01              Driver Version: 591.74         CUDA Version: 13.1     |
+-----------------------------------------+------------------------+----------------------+
| GPU  Name                 Persistence-M | Bus-Id          Disp.A | Volatile Uncorr. ECC |
| Fan  Temp   Perf          Pwr:Usage/Cap |           Memory-Usage | GPU-Util  Compute M. |
|                                         |                        |               MIG M. |
|=========================================+========================+======================|
|   0  NVIDIA GeForce RTX 5070 Ti     On  |   00000000:01:00.0  On |                  N/A |
| 30%   65C    P1            239W /  300W |    5207MiB /  16303MiB |     100%      Default |
|                                         |                        |                  N/A |
+-----------------------------------------+------------------------+----------------------+

+-----------------------------------------------------------------------------------------+
| Processes:                                                                              |
|  GPU   GI   CI              PID   Type   Process name                        GPU Memory |
|        ID   ID                                                               Usage      |
|=========================================================================================|
|    0   N/A  N/A               39      G   /Xwayland                                N/A |
|    0   N/A  N/A            57077      C   /busy                                    N/A |
+-----------------------------------------------------------------------------------------+
```

1.2.1. Cuestiones

1.2.1.1. ¿Qué campos cambian (utilización, memoria, potencia, clocks)?

La memoria se ocupa en algo más de 5 GB, la utilización pasa al 100% lo que significa que no toda la memoria está ocupada pero las SM están todas ocupadas, la potencia pasa al máximo por eso mismo y de clocks no veo nada.

1.2.1.2. ¿Por qué un kernel “que tarda” ayuda a ver actividad en nvidia-smi?

Porque smi muestrea cada x tiempo que le digas entonces ves las instantáneas pero no hace profiling de nada, por lo que ver un kernel que tarda te da tiempo a ver los cambios.

1.2.1.3. ¿Qué esperas que ocurra si reduces N drásticamente? ¿Y si reduces el bucle interno?

Sin haberlo probado, entiendo que con N reduzco la memoria ocupada porque hay menos hilos y también por tanto el cómputo, y reduciendo el bucle interno reduzco el tiempo que dura.

1.3. Parte C — Consulta programática de propiedades (API CUDA)

Device 0: NVIDIA GeForce RTX 5070 Ti
Compute capability: 12.0
Número de SMs: 70
Warp size: 32
Memoria global total: 17094475776
SharedMemPerBlock: 49152
RegsPerBlock: 65536
MaxThreadsPerMultiProcesor: 1024
MaxThreadsPerMultiProcesor: 1536

1.3.1. Cuestiones

1.3.1.1. ¿Qué significa warpSize y por qué aparece como propiedad explícita?

Los 32 hilos en los que se dividen los bloques como estándar desde hace tiempo. Entiendo que aparece por compatibilidad si cambia en el futuro o cuando cambió en el pasado.

1.3.1.2. ¿Qué recursos (a nivel de SM) sugieren sharedMemPerBlock y regsPerBlock?

Son la memoria compartida y registros por bloque disponibles respectivamente.

1.3.1.3. ¿Qué información de query.cu te será útil para razonar sobre ocupación en sesiones posteriores?

La compute capability, el número de SMs, técnicamente el warp size, shared memory per block, registers per block, max threads per multiprocessor.

1.3.1.4. Cita (con enlace) la sección de la documentación donde se describe cudaGetDeviceProperties o cudaDeviceProp.

https://docs.nvidia.com/cuda/cuda-runtime-api/group__CUDART__DEVICE.html#group__CUDART__DEVICE_1g1bf9d625a931d657e08db2b4391170f0

1.3.2. Ampliaciones:

Límites de grid x: 2147483647
Límites de grid y: 65535
Límites de grid z: 65535
Tamaño de la cache L2: 50331648
Ancho de banda global en bits: 256

2. Ejercicio 2 — Caracterización de transferencias CPU/GPU y GPU/GPU

2.1. Tablas…

10 iteraciones: [enlace al sheet]

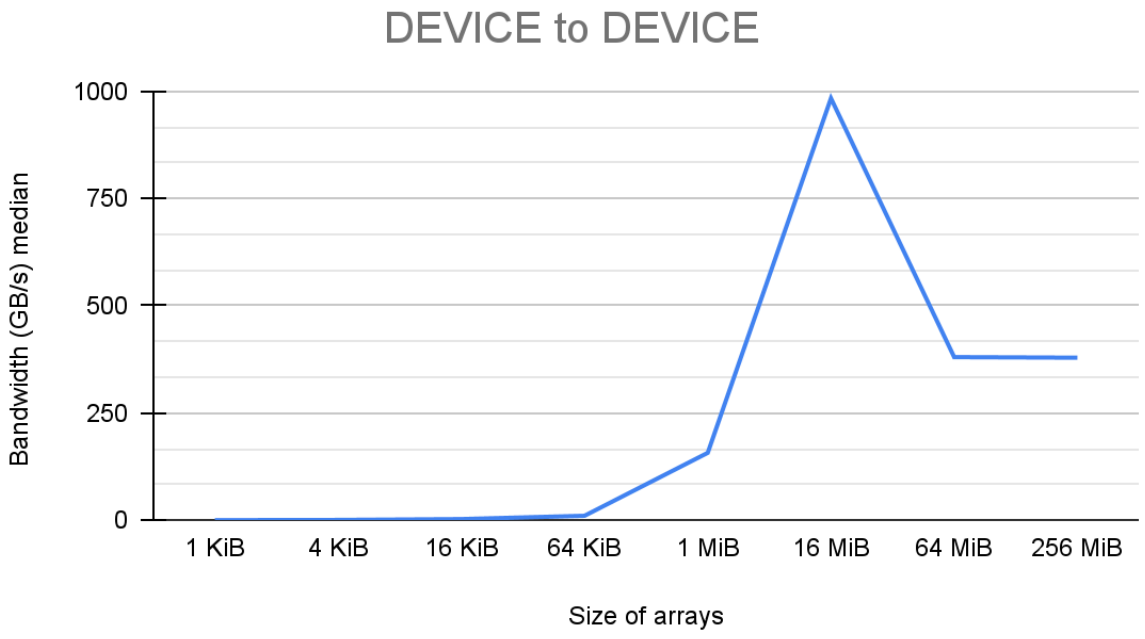

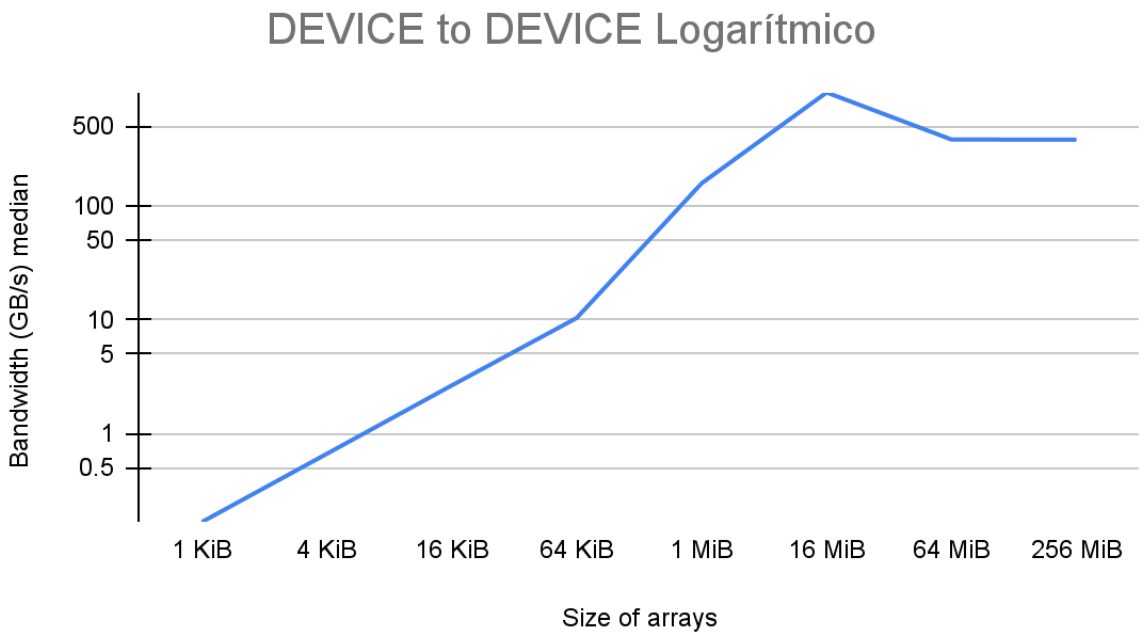

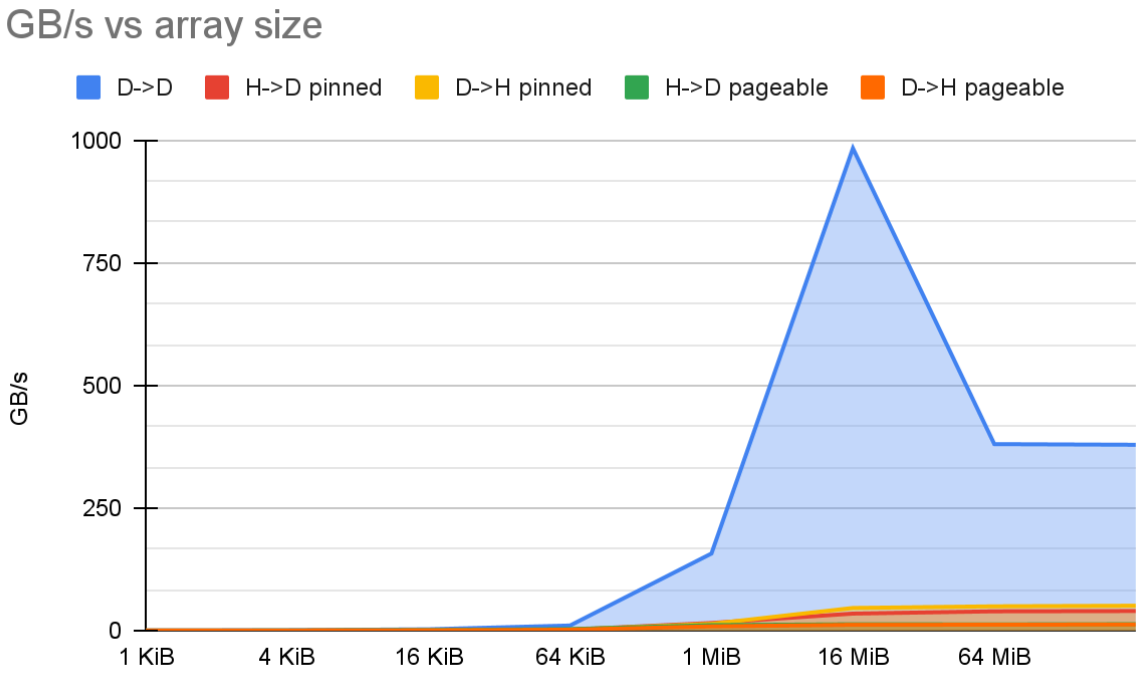
GB/s vs array size
D->D
H->D pinned
D->H pinned
H->D pageable
D->H pageable
GB/s
1000
750
500
250
0
1 KiB
4 KiB
16 KiB
64 KiB
1 MiB
16 MiB
64 MiB

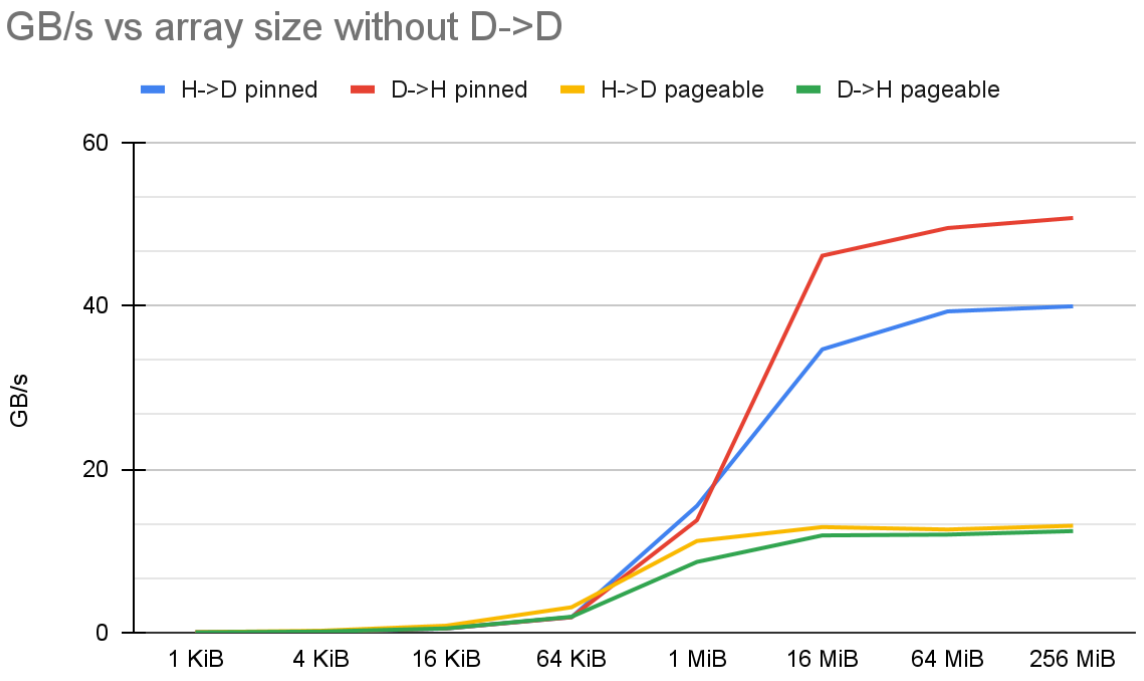
GB/s vs array size without D->D
H->D pinned
D->H pinned
H->D pageable
D->H pageable
GB/s
60
40
20
0
1 KiB
4 KiB
16 KiB
64 KiB
1 MiB
16 MiB
64 MiB
256 MiB

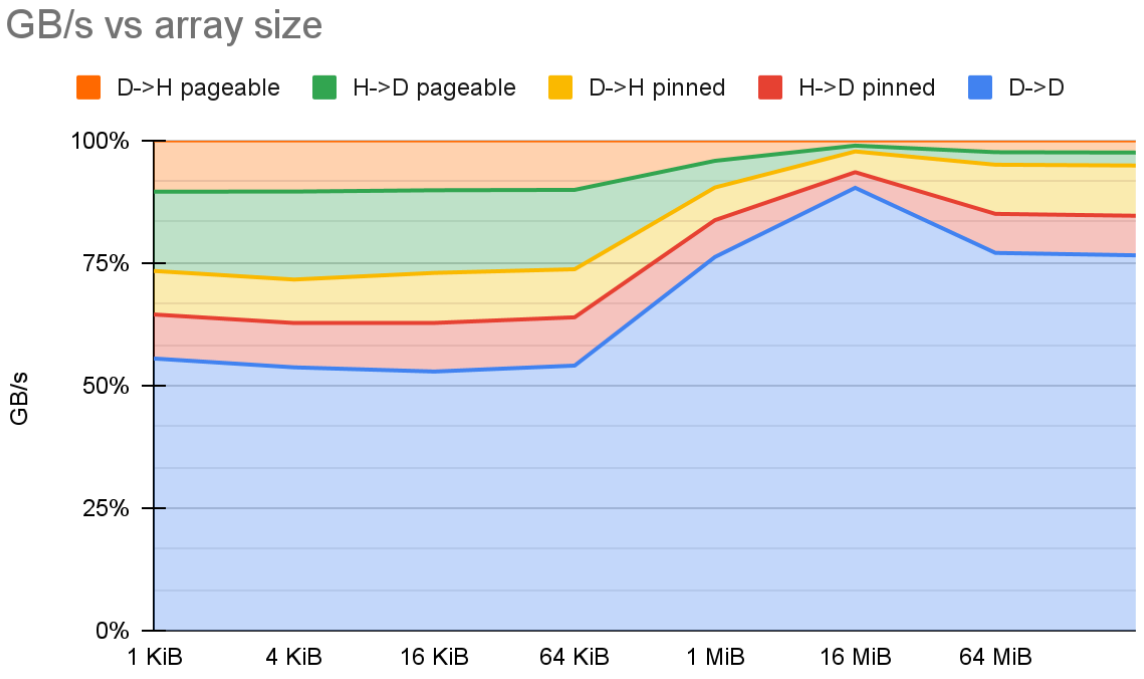
GB/s vs array size
D->H pageable
H->D pageable
D->H pinned
H->D pinned
D->D
100%
75%
50%
25%
0%
GB/s
1 KiB
4 KiB
16 KiB
64 KiB
1 MiB
16 MiB
64 MiB

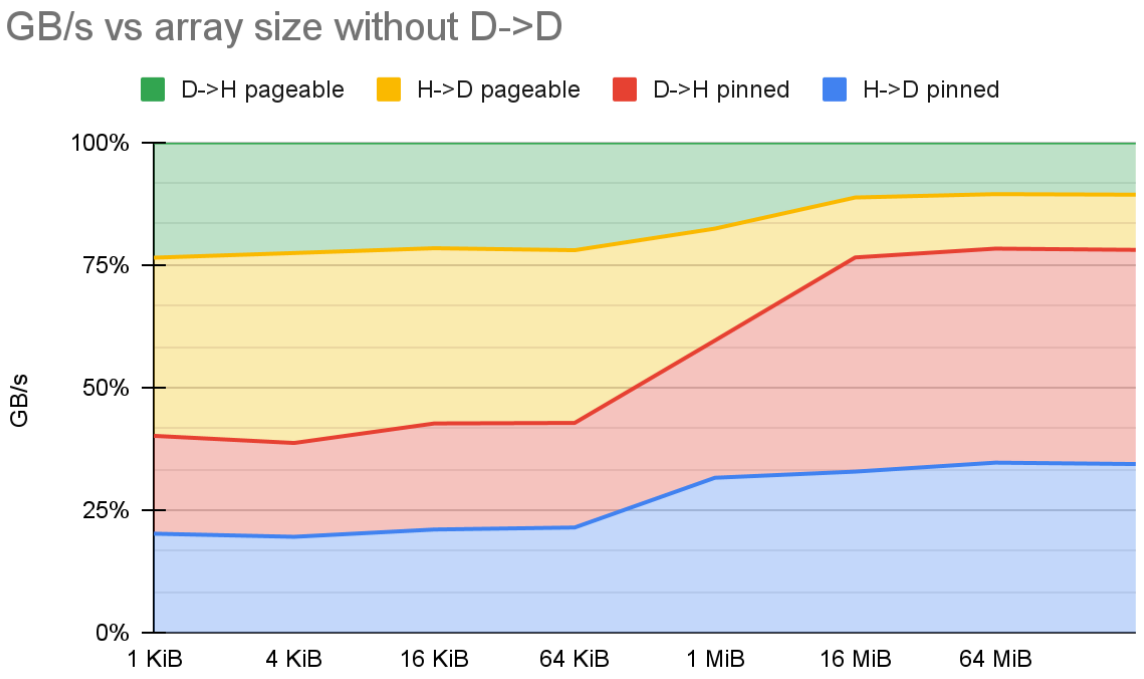
GB/s vs array size without D->D
D->H pageable
H->D pageable
D->H pinned
H->D pinned
100%
75%
50%
25%
0%
GB/s
1 KiB
4 KiB
16 KiB
64 KiB
1 MiB
16 MiB
64 MiB

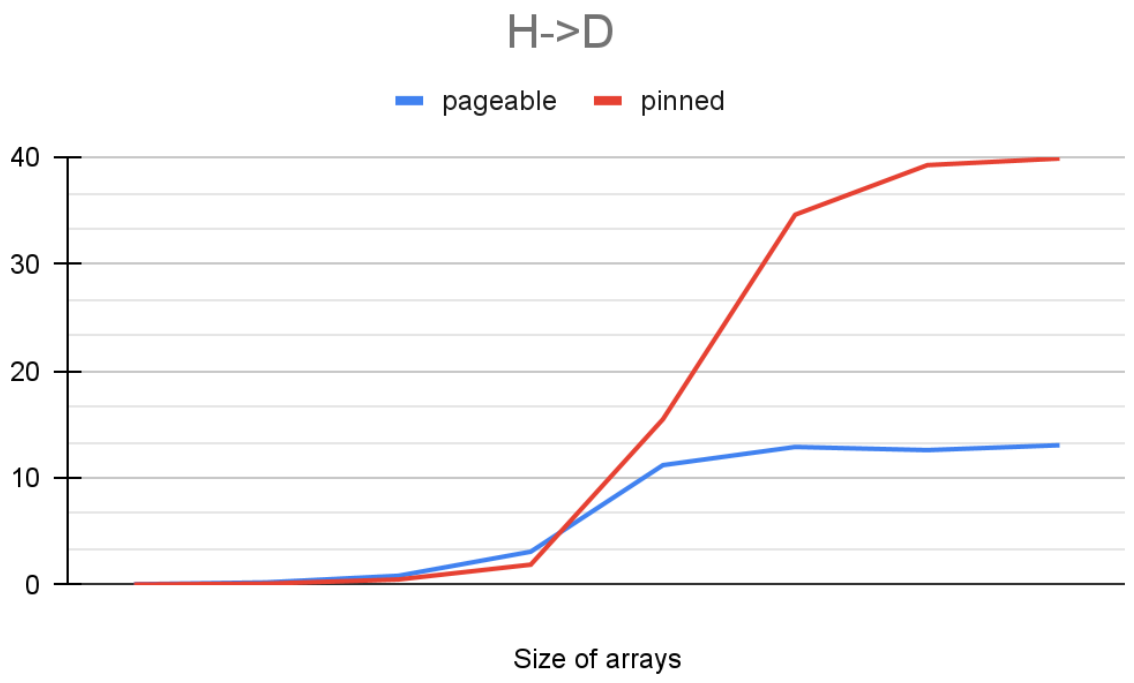
H->D
pageable
pinned
40
30
20
10
0
Size of arrays

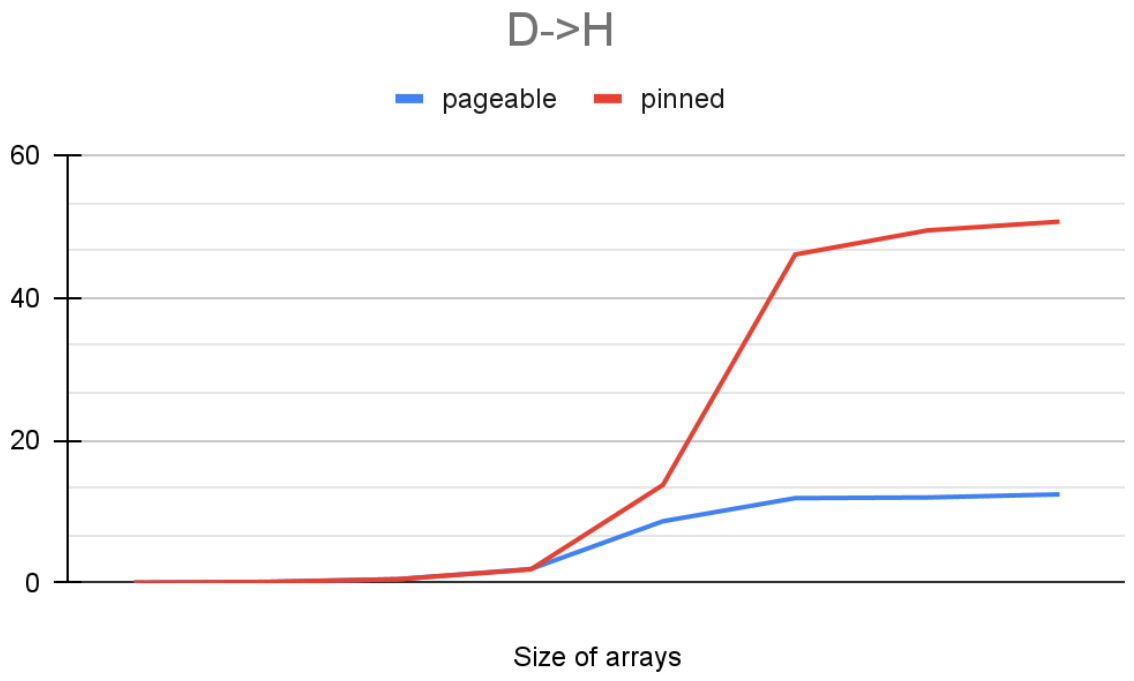
D->H
pageable
pinned
60
40
20
0
Size of arrays

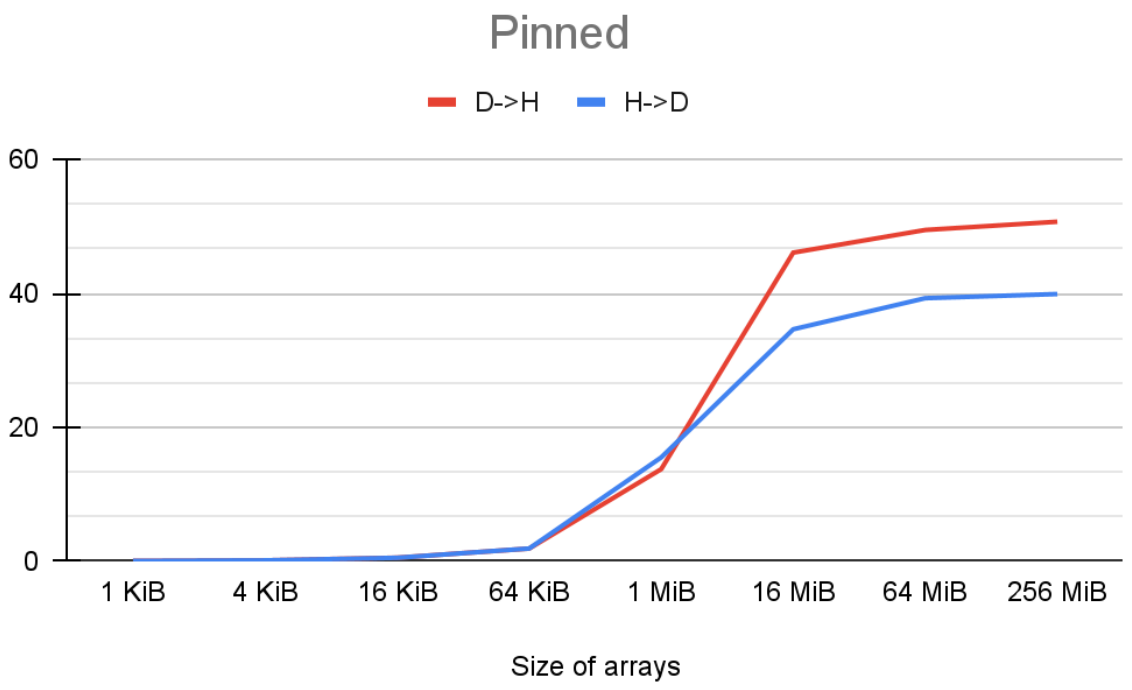

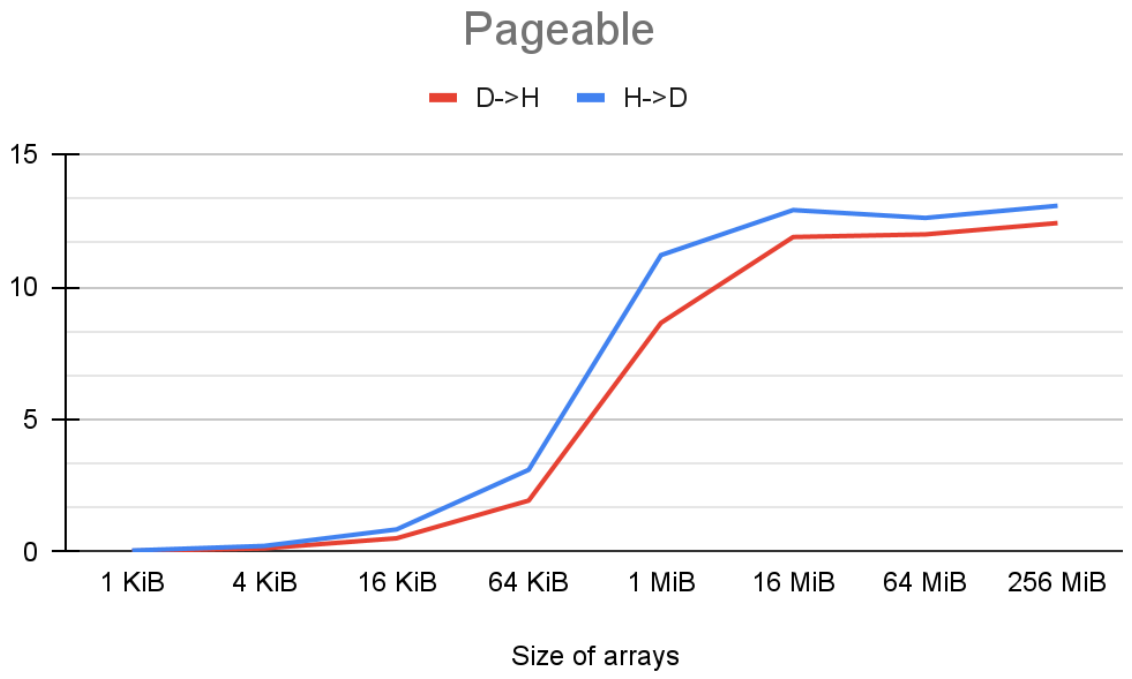

2.2. Cuestiones

2.2.1. ¿Por qué BW es bajo en tamaños pequeños? Relaciónalo con latencia y overhead fijo.

Porque el coste de la transferencia no viene determinado por la velocidad real ni el ancho de banda porque no se amortizan, el cuello de botella real en tamaños tan pequeños es la latencia de las operaciones, la comunicación CPU/GPU y el overhead fijo, todos los costes que no dependen del tamaño de los datos

2.2.2. ¿A partir de qué tamaño se estabiliza BW en tu sistema?

Hay un pico raro en 16 MiB, especialmente en D2D, pero todo lo demás a partir de ahí es estable y llega a la meseta en todas las pruebas que he hecho.

2.2.3. ¿Hay asimetría (H→D ≠ D→H)? ¿Cuánto difieren aproximadamente en el régimen de saturación?

Sí que la hay, en general todos los movimientos pinned D->H suelen tener mayor o igual ancho de banda que los H->D, o lo que es lo mismo, los movimientos H->D tienden a ser más lentos. En pageable se mantienen muy parecidos siendo D->H el ligeramente más lento, pero muy poco en comparación con lo rápido que es pinned frente a pageable.

A partir de la saturación D->H suele ser un 27% más rápido que H->D en pinned, y alrededor de un 5% más lento en pageable.

2.2.4. ¿Por qué pinned suele mejorar BW?

Porque bloquea en RAM la memoria que va a usar y permite acceso directo por PCIe con el DMA. No hacerlo hace que el SO pueda moverla según necesite y genera pasos intermedios con el SO, fastidiando así el DMA.

2.2.5. ¿Por qué D→D es muy superior a CPU/GPU en general?

Porque es acceso de VRAM directo en la propia GPU, que no pasa por el bottleneck del bus del PCIe entre CPU y GPU.

3. Ejercicio 3 — Suma de vectores con tamaños crecientes (CPU vs GPU)
   google sheets
   3.1. Gráficas:
      3.1.1. Tiempo vs N (CPU y GPU total).

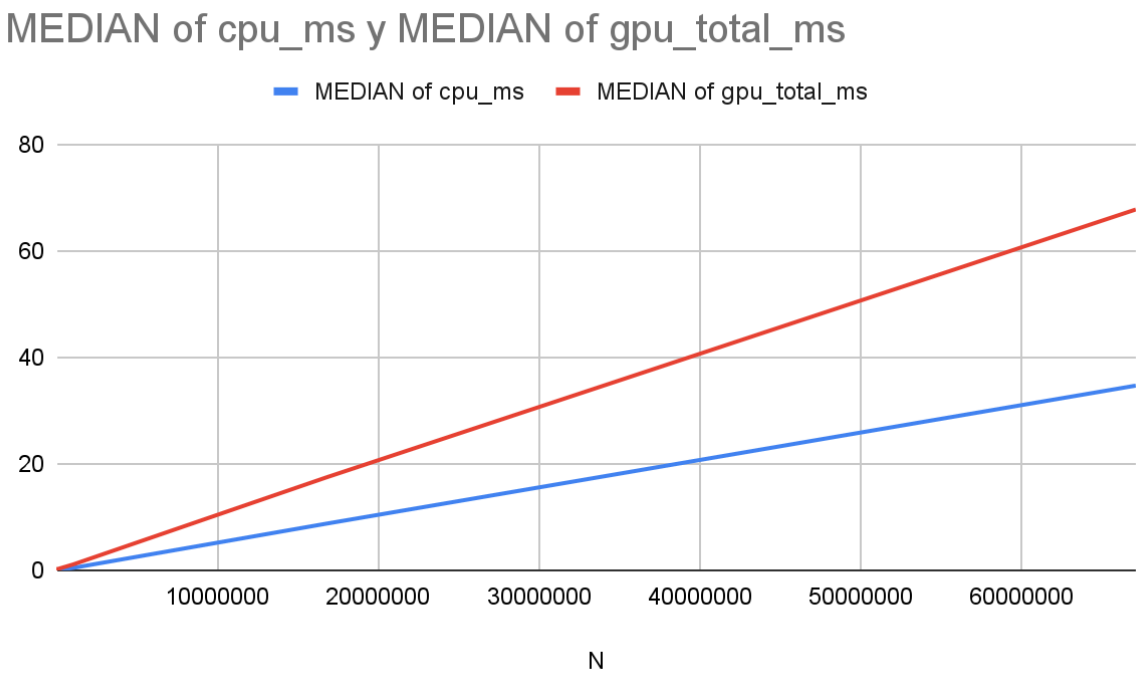

      3.1.2. Tiempo kernel vs N (solo GPU kernel).

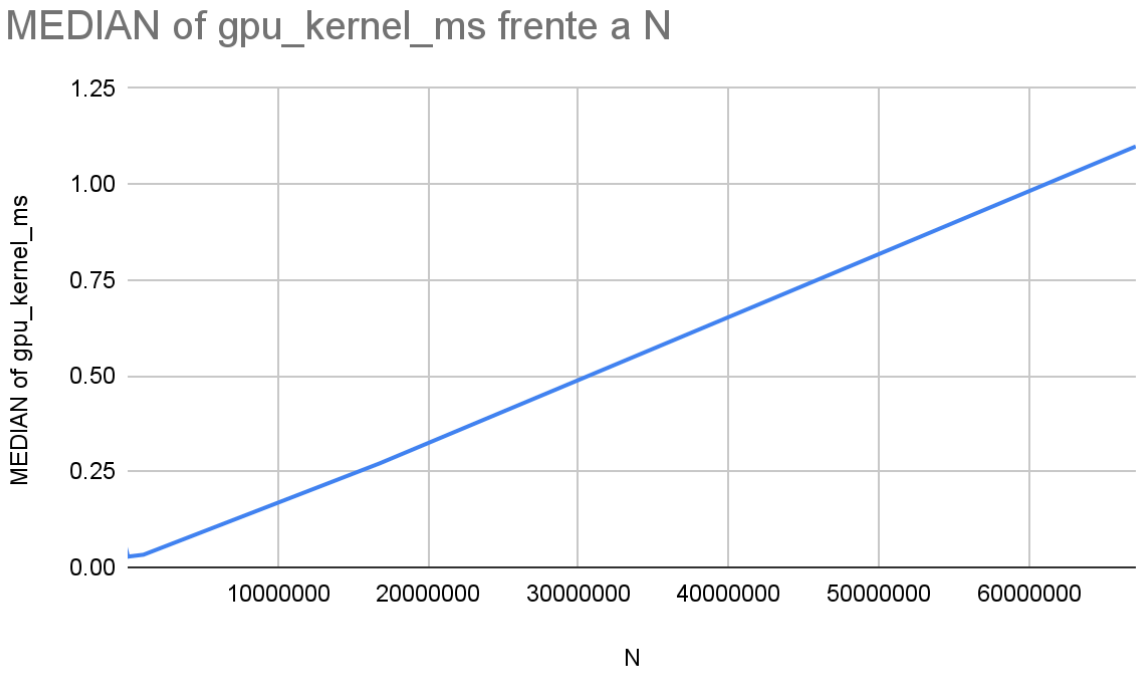

      3.1.3. Throughput efectivo (GB/s) vs N para CPU y GPU (total y/o kernel).

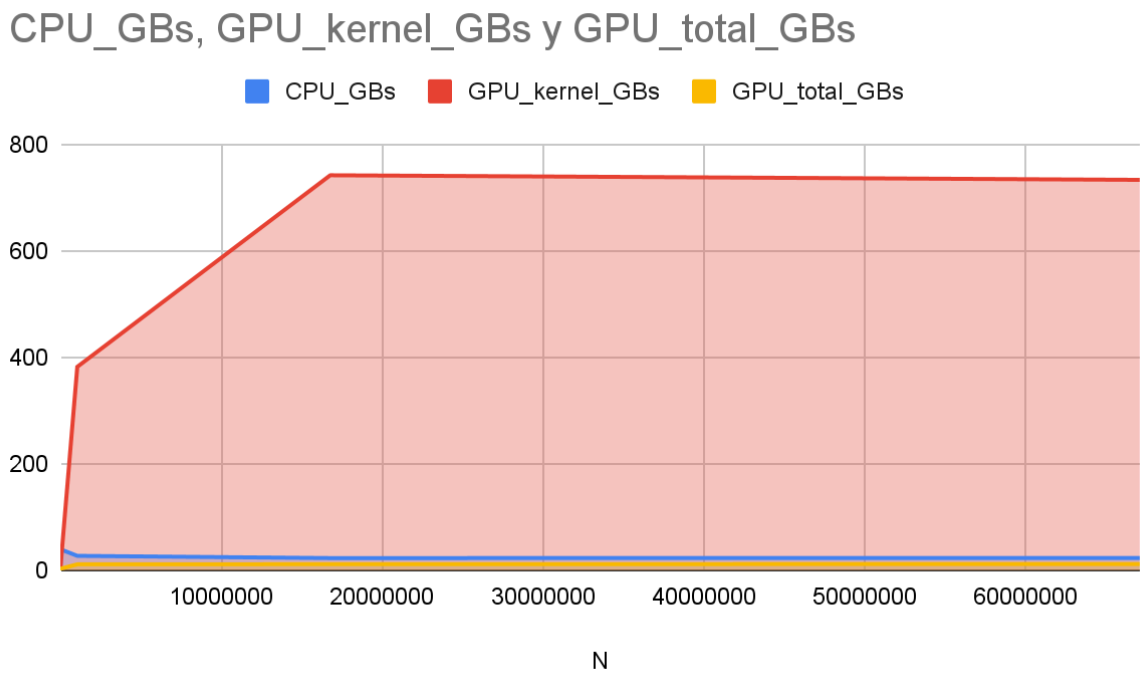

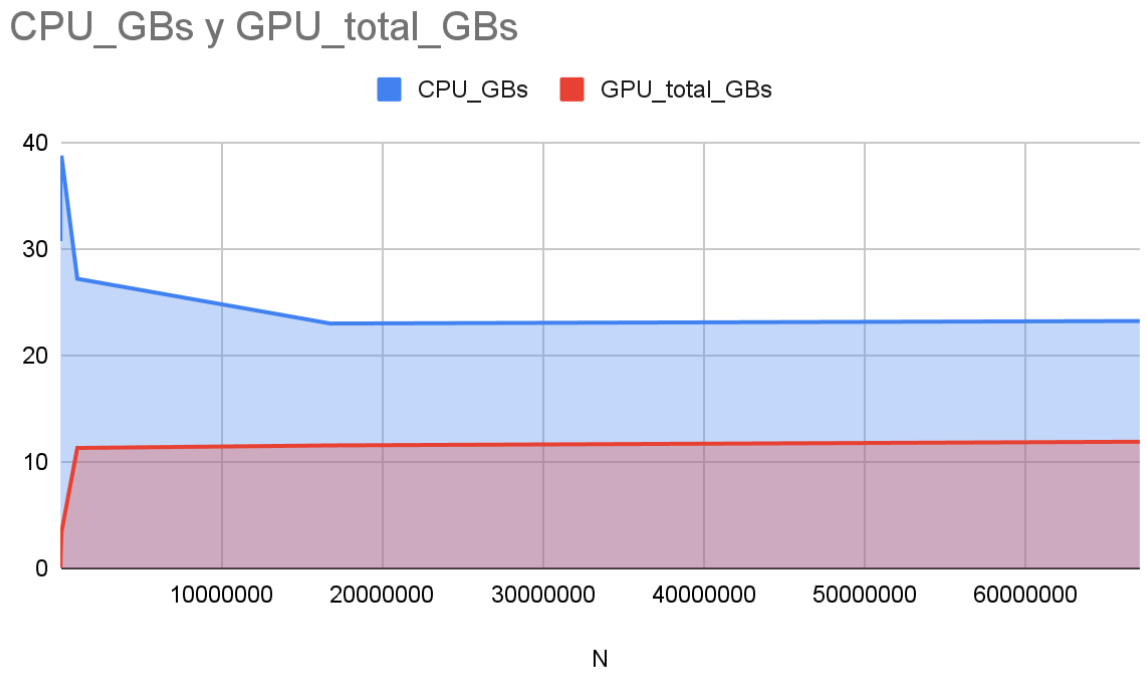

3.1.4. Speedup vs N (CPU / GPU total).

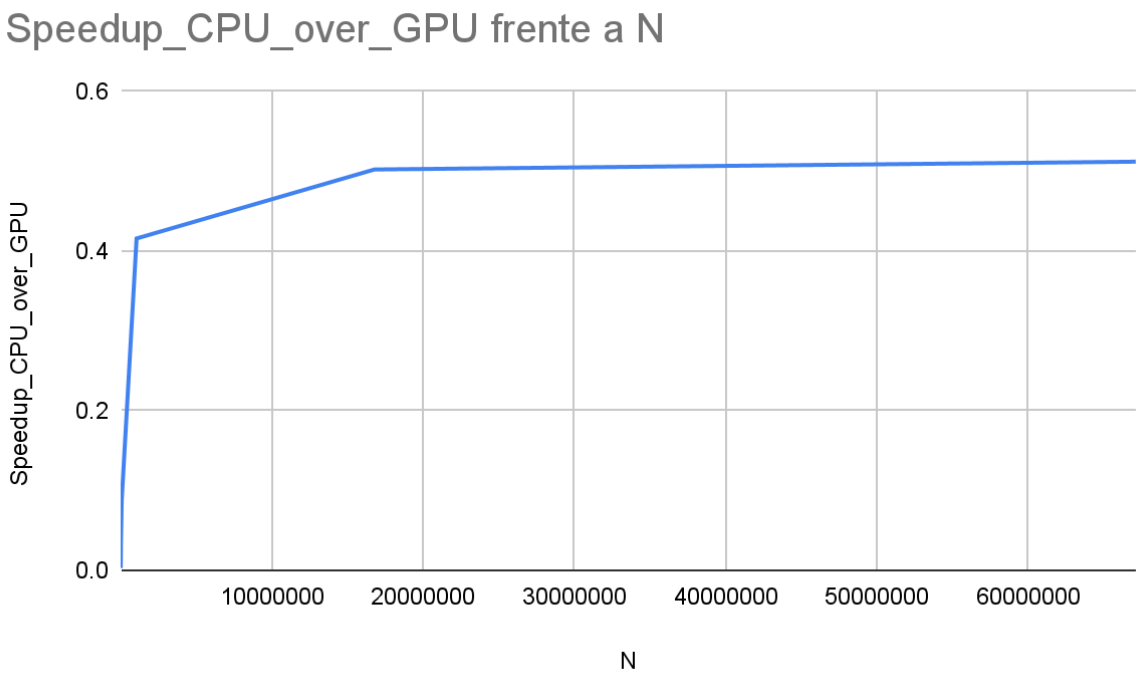

3.2. Cuestiones:

3.2.1. ¿Existe un tamaño mínimo a partir del cual la GPU gana claramente? ¿Por qué?

No, porque solo varía el tamaño y la GPU no aplica ninguna ventaja sobre eso, el cómputo por dato es siempre el mismo y por tanto no se amortiza frente al overhead que acarrea el movimiento de los datos.

3.2.2. ¿Qué domina el tiempo total GPU: transferencias o kernel? ¿Cómo cambia con N ?

Sin duda el de las transferencias. El de kernel es muy muy rápido. Aumenta linealmente con N.

3.2.3. Compara tus conclusiones con los resultados del Ejercicio 2 (PCIe). ¿Son consistentes?

Sí, se aprecia perfectamente el bottleneck de las transferencias frente a la optimización por kernel vs CPU.